

KerNet: un nuevo enfoque de aprendizaje profundo para la detección del queratocono y del queratocono subclínico basado en los datos brutos del sistema Pentacam HR

Ruiwei Feng¹, Zhe Xu, Xiangshang Zheng, Heping Hu, Xiuming Jin, Danny Z. Chen², *miembro del IEEE*, Ke Yao y Jian Wu, *miembro del IEEE*

Resumen: El queratocono es una de las enfermedades corneales más graves, difícil de detectar en su fase inicial (es decir, el queratocono subclínico) y que puede provocar la pérdida de la visión. En este artículo, proponemos un novedoso enfoque de aprendizaje profundo de extremo a extremo, denominado KerNet, que procesa los datos brutos del sistema Pentacam HR (compuestos por cinco matrices numéricas) para detectar el queratocono y el queratocono subclínico. En concreto, proponemos una novedosa red neuronal convolucional, denominada KerNet, que contiene cinco ramas como estructura principal con una arquitectura de fusión multinivel. Las cinco ramas reciben cinco matrices por separado y captan eficazmente las características de las diferentes matrices mediante varios bloques residuales en cascada. La arquitectura de fusión multinivel (es decir, fusión de bajo nivel y fusión de alto nivel) tiene en cuenta de forma moderada la correlación entre los cinco cortes y fusiona las características extraídas para obtener una mejor predicción. Los resultados experimentales muestran que: (1) nuestro novedoso enfoque supera a los métodos de vanguardia en un conjunto de datos propio,

(correo electrónico: x_z_dahaizhe@zju.edu.cn ; lzjxm@zju.edu.cn ; xlren@zju.edu.cn).
Identificador de objeto digital 10.1109/JBHI.2021.3079430

Manuscrito recibido el 14 de octubre de 2020; revisado el 24 de febrero de 2021 y el 16 de abril de 2021; aceptado el 8 de mayo de 2021. Fecha de publicación: 12 de mayo de 2021; fecha de la versión actual: 5 de octubre de 2021. Esta investigación ha sido financiada en parte por el Programa Nacional de Investigación y Desarrollo de China, con la subvención 2019YFB1404802; en parte por la Fundación Nacional de Ciencias Naturales de China, con la subvención 61672453; y en parte por la Fundación Educativa de la Universidad de Zhejiang, con las subvenciones K18-511120-004, y K17-511120-017 y K17-518051-02, en parte por el proyecto de investigación tecnológica de interés público de Zhejiang con la subvención LGF20F020013, en parte por el Proyecto de Investigación Médica y Sanitaria de la provincia de Zhejiang (China), con la subvención 2019KY667; en parte por el Programa de Incorporación de Equipos Líderes en Innovación y Emprendimiento de Zhejiang, con la subvención 019R01007; en parte por la Oficina de Ciencia y Tecnología de Wenzhou (China), con la subvención Y2020082; y en parte por el Laboratorio Clave de Neurobiología Médica de la provincia de Zhejiang. El trabajo de Danny Z. Chen ha sido financiado en parte por la subvención CCF-1617735 de la NSF. (Ruiwei Feng, Zhe Xu y Xiangshang Zheng han contribuido por igual a este trabajo.) (Autores correspondientes: Jian Wu; Ke Yao.)

Ruiwei Feng, Xiangshang Zheng, Heping Hu y Jian Wu pertenecen a la Facultad de Informática y Tecnología de la Universidad de Zhejiang, Hangzhou 310027, China (correo electrónico: ruiwei_feng@zju.edu.cn ; xszheng@zju.edu.cn ; huheping@zju.edu.cn ; wujian2000@zju.edu.cn). Danny Z. Chen pertenece al Departamento de Informática e Ingeniería de la Universidad de Notre Dame, Notre Dame, IN 46556, EE. UU. (correo electrónico: dchen@nd.edu).

Zhe Xu, Xiuming Jin y Ke Yao pertenecen al Centro Oftalmológico del Segundo Hospital Afiliado de la Universidad de Zhejiang, Hangzhou, provincia de Zhejiang, China, y también a la Facultad de Medicina de la Universidad de Zhejiang, Hangzhou, provincia de Zhejiang 310027, China

en aproximadamente un 1 % en la precisión de detección del queratocono y en aproximadamente 4 en la precisión de detección del queratocono subclínico; (2) los mapas de atención visualizados por Grad-CAM muestran que nuestra red KerNet presta mayor atención a la parte temporal inferior en el caso del queratocono subclínico, lo cual se ha demostrado en estudios clínicos previos como la región clave que los oftalmólogos tienen en cuenta para detectar el queratocono subclínico. Según nuestro conocimiento, somos los primeros en proponer un enfoque de aprendizaje profundo de extremo a extremo que utilice datos sin procesar obtenidos mediante el sistema Pentacam HR para la detección del queratocono y del queratocono subclínico. Además, el rendimiento predictivo y la relevancia clínica de nuestra red KerNet han sido evaluados y corroborados satisfactoriamente por dos expertos clínicos. Nuestro código está disponible en <https://github.com/upzheng/Keratoconus>.

Términos clave: queratocono, queratocono subclínico, sistema Pentacam HR, datos sin procesar, aprendizaje profundo de extremo a extremo.

I. INTRODUCCIÓN

El queratocono es una de las enfermedades corneales más graves del mundo, que puede provocar astigmatismo irregular, edema corneal y, en última instancia, una pérdida grave de la

visión [1]. La detección y la intervención tempranas pueden aliviar la carga que suponen los costes del tratamiento e incluso evitar que los pacientes con queratocono sufran pérdida de visión.

Clínicamente, el queratocono se caracteriza por la dilatación corneal, el adelgazamiento central y una forma cónica. Los oftalmólogos suelen diagnosticar esta enfermedad basándose en la topografía y la tomografía corneales, que describen la curvatura de la superficie de la

[2].

El sistema Pentacam HR es una de las herramientas fiables y de uso habitual que ayudan a los oftalmólogos a detectar el queratocono. Consta de una cámara Scheimpflug giratoria y un software Pentacam. La cámara se utiliza para recopilar datos geométricos tridimensionales de la córnea de los ojos, y el software analiza y visualiza los datos para los oftalmólogos. De este modo, el sistema Pentacam HR ofrece a los oftalmólogos, de forma eficaz y visual, una serie de parámetros calculados (miles de dimensiones de índices normalizados), seis mapas topográficos corneales (de curvatura, elevación y paquimetría) y una imagen tridimensional de la córnea. Por lo tanto, un oftalmólogo con experiencia puede detectar el queratocono basándose en la información visualizada que proporciona el sistema Pentacam HR. Sin embargo, dicho procedimiento para el diagnóstico del queratocono asistido por Pentacam

2168-2194 © 2021 IEEE. Se permite el uso personal, pero la republicación o redistribución requiere la autorización del IEEE. Consulte <https://www.ieee.org/publications/rights/index.html> para obtener más información.

por lo general requiere mucho tiempo y la precisión de la detección depende de la experiencia. Además, a los oftalmólogos les resulta bastante difícil distinguir a un paciente con queratocono subclínico de una persona sana [3], ya que los índices normalizados y los mapas topográficos corneales visualizados pueden presentar algunos datos faltantes y, por lo tanto, mostrar pocas características evidentes de los ojos con queratocono subclínico.

Para abordar estas cuestiones, se han propuesto numerosos métodos de aprendizaje automático con el fin de ayudar a los oftalmólogos a detectar el queratocono de forma más eficiente basándose en el sistema Pentacam HR. Sin embargo, la mayoría de estos métodos se utilizaron como sustituto del oftalmólogo en el procedimiento de detección mencionado anteriormente. Es decir, estos métodos solían recibir, para su procesamiento y modelización, bien los mapas topográficos corneales [4], bien los índices normalizados [2] generados por el software de Pentacam. De este modo, el software de Pentacam desempeñaba un papel importante como potente herramienta de preprocesamiento. Aunque este software permitía tanto a los oftalmólogos como a los modelos de aprendizaje automático obtener datos de menor dimensión de forma intuitiva, presenta ciertos inconvenientes clave. Por ejemplo, se observó [3] que ni los oftalmólogos ni los métodos conocidos de aprendizaje automático podían detectar eficazmente el queratocono subclínico basándose en los datos procesados mencionados anteriormente, posiblemente debido a que se omitía cierta información durante el proceso de tratamiento de datos por parte del software de Pentacam. Sin embargo, esa información omitida podría ser relevante para la detección del queratocono subclínico. Por lo tanto, consideramos que deberían utilizarse datos más completos y en bruto, sin haber sido procesados por el software de Pentacam, para detectar el queratocono subclínico, así como para mejorar la precisión de dicha detección. Según nuestro conocimiento, se han realizado pocos estudios para detectar el queratocono subclínico utilizando un enfoque de aprendizaje profundo y analizando directamente los datos en bruto del sistema Pentacam HR.

En este artículo, nuestro objetivo es subsanar la carencia existente en cuanto al aprovechamiento de los datos brutos recopilados por el sistema Pentacam HR para la detección del queratocono y del queratocono subclínico. Concretamente, los datos brutos generados por el sistema Pentacam HR consisten en tres archivos CSV que contienen cinco matrices, correspondientes a los datos geométricos tridimensionales de la córnea obtenidos por la cámara Pentacam sobre la curvatura de las superficies anterior y posterior, la elevación de las superficies anterior y posterior y la paquimetría de los ojos. Cada matriz tiene un tamaño de 141×141 y los elementos distintos de cero en cada matriz reflejan la forma de la córnea. Empíricamente, debería existir cierta asociación implícita entre estas cinco matrices, aunque es probable que dicha asociación no sea tan fuerte como la que existe entre los canales de una imagen RGB. Por lo tanto, en lugar de considerar imprudentemente las cinco matrices como un todo, las tratamos de forma innovadora como cinco cortes de imagen. Desde este punto de vista, se espera que un modelo específico tome las cinco matrices respectivamente como entrada para extraer características y, a continuación, fusione las características capturadas de alguna manera para obtener una mejor predicción.

Proponemos un novedoso enfoque de aprendizaje profundo, denominado KerNet, que está cuidadosamente diseñado para

adaptarse al formato específico de los datos sin procesar mediante la introducción del concepto de fusión multinivel. Nuestra red KerNet consta de cinco ramas, cada una de las cuales contiene cuatro bloques convolucionales con la estructura residual de ResNet [5] y recibe un corte de imagen como entrada. Introducimos el concepto de fusión multinivel para fusionar las características capturadas de cada corte. La arquitectura de fusión multinivel se implementa mediante

la fusión de bajo nivel y la fusión de alto nivel, que son las dos formas principales de fusión multimodal [6]. Para la fusión de bajo nivel, establecemos conexiones cruzadas entre ramas vecinas para la fusión de características, seguidas de un módulo específico de atención espacial. Para la fusión de alto nivel, los mapas de características generados por las cinco ramas se concatenan por canales para la predicción final, tal y como se ilustra en la *fig. 1*. Nuestras principales contribuciones son las siguientes.

- En primer lugar, según nuestro conocimiento, proponemos la primera red de aprendizaje profundo de extremo a extremo de aprendizaje profundo de extremo a extremo que utiliza los datos brutos obtenidos por el sistema Pentacam HR para la detección del queratocono y del queratocono subclínico, en lugar de utilizar los datos procesados por el software de Pentacam como en los métodos anteriores [2], [4].
- En segundo lugar, proponemos una estructura novedosa, KerNet, que recibe los datos sin procesar generados por el sistema Pentacam HR para la extracción de características y la predicción final, y trata los datos de forma específica como cinco cortes de imagen. De este modo, nuestra KerNet ofrece una nueva forma de aplicar modelos de aprendizaje profundo para la detección de enfermedades oftálmicas utilizando datos de un formato similar al de los datos brutos utilizados en nuestro estudio.

- Por último, las evaluaciones experimentales demuestran: (1)

que nuestro

KerNet puede detectar eficazmente el queratocono subclínico, lo cual supone una tarea difícil tanto para los oftalmólogos como para los métodos anteriores de aprendizaje automático [3] basados en datos procesados; (2) nuestro KerNet supera a varias redes de aprendizaje profundo muy conocidas y alcanza un rendimiento de vanguardia tanto en la detección del queratocono como del queratocono subclínico; (3) el rendimiento de nuestra red KerNet ha sido verificado y su relevancia clínica ha sido confirmada por dos expertos independientes.

El resto de este artículo se organiza de la siguiente manera. En la sección II, revisamos los trabajos relacionados con la detección del queratocono y del queratocono subclínico basados en los datos procesados mencionados anteriormente, así como el desarrollo de métodos de aprendizaje profundo y sus aplicaciones en oftalmología. En la sección III, presentamos los datos utilizados en este estudio (incluido el procedimiento de recopilación y la distribución del conjunto de datos) y la estructura de nuestra red KerNet. A continuación, en la sección IV, llevamos a cabo numerosos experimentos para verificar la eficacia de nuestra red KerNet. Por último, concluimos este artículo en la sección V.

II. TRABAJOS RELACIONADOS

A. Detección del queratocono asistida por Pentacam

Recientemente se han llevado a cabo numerosos estudios para la detección del queratocono utilizando el sistema Pentacam HR. La mayoría de estas investigaciones se basaron en los datos procesados por el software de Pentacam (por ejemplo, índices calculados o imágenes visualizadas), y pocas

se basaron en datos sin procesar, tal y como se menciona en la sección I. Estos métodos pueden dividirse a grandes rasgos en tres grupos según los diferentes formatos de los datos que utilizaron.

- 1) Se han realizado numerosos trabajos basados en los índices calculados o incluso en parte de dichos índices [7]–[12]. Estas investigaciones solían emplear métodos básicos de análisis estadístico [13]–[17] o modelos tradicionales de aprendizaje automático [3], [18]–[22] para distinguir el queratocono (incluido el queratocono subclínico) de los ojos normales, con una capacidad limitada




Fig. 1. Ilustración de nuestro modelo KerNet. I_i ($i \in \{1, 2, 3, 4, 5\}$) denota diferentes cortes de entrada y O denota la predicción de salida. Destacamos con un fondo amarillo las operaciones de fusión de bajo nivel y de alto nivel en nuestro KerNet. R_{ij} ($i \in \{1, 2, 3, 4, 5\}$, $j \in \{1, 2, 3, 4\}$) representa los bloques residuales y A_i ($i \in \{1, 2, 3, 4, 5\}$) representa los bloques de atención. Se utilizan diferentes subíndices para mostrar la diversidad de los parámetros en los distintos bloques o módulos. Además, los mapas de características de salida de cada bloque o módulo se muestran mediante cubos de diferentes colores, con sus tamaños ilustrados ($C \times W \times H$, donde C es el tamaño del canal de un mapa de características).

Número de parámetros calculados obtenidos por el sistema Pentacam HR. Por ejemplo, se evaluó el rendimiento de un algoritmo de máquina de vectores de soporte utilizando 22 parámetros seleccionados [21]. Se aplicaron algoritmos de regresión logística para detectar los casos de queratocono subclínico y definitivo [18], [22]. Se realizaron estudios basados en 55 parámetros [3] y 28 parámetros [19]. Recientemente, Hallett *et al.* [2] propusieron un método de aprendizaje profundo basado en el conjunto de los parámetros calculados (el índice de progresión de Pentacam, PPI) para la clasificación del queratocono.

- 2) Un pequeño número de estudios se basó en imágenes topográficas visualizadas mediante el sistema Pentacam HR [23]. Toutounchian *et al.* [4] propusieron un algoritmo de inteligencia artificial para identificar el queratocono utilizando características de los mapas topográficos obtenidos mediante el sistema Pentacam HR. Lavric *et al.* [14] **propusieron una red neuronal convolucional (CNN)** para distinguir el queratocono de los ojos normales utilizando **un conjunto de datos de 3 000** imágenes de topografía corneal. Este trabajo se consideró el primero en integrar una red neuronal convolucional en el proceso de diagnóstico del queratocono. Además, Kovacs *et al.* [13] midieron datos tomográficos, datos topográficos e índices de queratocono basados en el sistema Pentacam HR. Los autores de [24] propusieron el modelo PIRSS, basado en imágenes tomográficas corneales, para detectar posibles candidatos a cirugía refractiva.
- 3) Se realizaron muy pocos estudios basados en los datos brutos obtenidos por el sistema Pentacam HR. En [25], se propuso un modelo matemático a medida para la selección de parámetros a partir de los datos brutos, y los parámetros seleccionados se utilizaron para detectar casos clínicos y sospechas de queratocono mediante una red neuronal de propagación hacia adelante (FFN). Aunque este trabajo utilizó datos brutos generados por el sistema Pentacam HR, no se trataba de un método integral para la detección

del queratocono.

B. Métodos de aprendizaje profundo y sus aplicaciones en oftalmología

Se han desarrollado numerosos métodos de aprendizaje profundo para el reconocimiento de imágenes desde que Krizhevsky *et al.* [26] propusieron AlexNet en el concurso ImageNet de 2012. Posteriormente, se propusieron VGGNet [27], GoogLeNet [28], ResNet [5], DenseNet [29] y otras redes neuronales convolucionales (CNN) para el reconocimiento de imágenes en muy diversos escenarios. Recientemente, el aprendizaje profundo se ha convertido en una de las herramientas más potentes para la detección de enfermedades y la clasificación de información médica [30]. En oftalmología, los métodos de aprendizaje profundo se han aplicado ampliamente para diagnosticar y detectar enfermedades, como la retinopatía diabética (RD) [31], la degeneración macular relacionada con la edad (DMAE) [32], el queratocono [14], las cataratas [33] y otras [34], tal y como se resume en [35]. En cuanto al queratocono, numerosos estudios han utilizado métodos de aprendizaje profundo para su detección y la clasificación de su gravedad a partir de diversos conjuntos de datos [36] (no solo datos obtenidos mediante el sistema Pentacam HR). En este artículo revisamos los trabajos que utilizan métodos de aprendizaje profundo basados en otros sistemas auxiliares. Kamiya *et al.* [37] aplicaron métodos de aprendizaje profundo para distinguir los diferentes grados de queratocono de los ojos normales basándose en seis mapas codificados por colores medidos mediante una tomografía de coherencia óptica del segmento anterior. Dos Santos *et al.* [38] propusieron un método de aprendizaje profundo, CorneaNet, para segmentar las imágenes de OCT de la córnea y detectar ojos con queratocono, basándose en un sistema de OCT de ultraalta resolución diseñado a medida. Varios métodos de aprendizaje profundo para la detección del queratocono se basaron en el sistema Artemis-1n [39], EyeSys [40] y CASIA ASOCT [37]. Además, en [41] se utilizó ResNet para la detección del queratocono a partir de los datos numéricos sin procesar del sistema Orbscan, que son bastante similares a los datos utilizados en este artículo. Sin embargo, para la detección del queratocono y del queratocono subclínico, aún no existen métodos de aprendizaje profundo de extremo a extremo basados en los datos sin procesar obtenidos por el sistema Pentacam HR.




Fig. 2. Ilustración de los datos brutos utilizados en este estudio: un ejemplo de un ojo con queratocono. Parte superior: cinco matrices numéricas de 141×141 cada una (de izquierda a derecha: curvatura de la superficie anterior, curvatura de la superficie posterior, elevación de la superficie anterior, elevación de la superficie posterior y paquimetría). Parte inferior: cinco gráficos de distribución de datos correspondientes a los cinco cortes, representados con el radio r (en el intervalo $[0,5 \text{ mm}, 5,5 \text{ mm}]$) en el eje x y los valores de media y desviación estándar en el eje y . En cada uno de estos gráficos, las curvas de diferentes colores representan los datos de los distintos grupos (queratocono: verde; queratocono subclínico: naranja; normal: azul).

III. MATERIALES Y MÉTODOS

La *fig. 1* ofrece una visión general de nuestra KerNet, una novedosa red de aprendizaje profundo de extremo a extremo para la detección del queratocono y del queratocono subclínico. Utilizando los datos brutos (cinco matrices por cada muestra) exportados del sistema Pentacam HR, KerNet clasifica las muestras en tres categorías: normal, queratocono subclínico y queratocono. En esta sección se describen, en primer lugar, los detalles de la recopilación y la distribución de nuestro conjunto de datos. A continuación, se presenta la estructura detallada de nuestra red KerNet.

A. Conjunto de datos

1) Recopilación de datos: En este estudio, hemos recopilado un conjunto de datos corneales utilizando el sistema Pentacam HR (Oculus, GmbH, Wetzlar, Alemania). Nuestro conjunto de datos contiene 854 muestras, incluidas 335 muestras normales (85 mujeres y 250 hombres; $24,3 \pm 2,4$ años), 172 muestras de queratocono subclínico (45 mujeres y 124 hombres; $22,3 \pm 5,6$ años) y 347 de queratocono (90 mujeres y 237 hombres; $24,2 \pm 5,7$ años). Solo se incluyó un ojo de cada paciente y sujeto. Los resultados del equivalente esférico (EE, dioptrías) de las muestras normales ($-4,96 \pm 2,23$ D) y de las muestras de queratocono subclínico ($-4,80 \pm 2,70$ D) fueron diferentes de los de las muestras de queratocono ($-7,37 \pm 4,54$ D; análisis de varianza ANOVA, $p < 0,05$). Los resultados de la agudeza visual mejor corregida (AVMC, AV decimal) de las muestras normales ($1,0 \pm 0,1$ D) y de las muestras con queratocono subclínico ($1,0 \pm 0,1$ D) fueron diferentes de los de las muestras con queratocono ($0,5 \pm 0,2$ D; análisis de varianza ANOVA, $p < 0,05$). Los análisis estadísticos mencionados se realizaron con el software Statistical Package for the Social Sciences (versión 17, SPSS, Inc., Chicago, IL, EE. UU.). Las comparaciones entre los grupos normal, de queratocono subclínico y de queratocono se realizaron mediante ANOVA. Se definió como nivel de significación estadística un valor de $P < 0,05$.

El procedimiento de exploración tomográfica corneal y de recogida de datos es el siguiente. En primer lugar, se pide al

sujeto que apoye la barbilla en el reposabarbo del instrumento de exploración, con la

la frente apoyada contra la banda frontal. Un operador sujeta la palanca y la ajusta según la orientación de la pantalla. Antes de la exploración, se pide al sujeto que parpadee completamente para que la córnea quede cubierta por una fina película lagrimal. A continuación, para obtener resultados aceptables, el sujeto debe mantener los ojos abiertos durante 2 segundos tras el escaneo con luz azul, hasta que la «Especificación de calidad de la exploración» indique «OK». Tras el examen, se recopila la información corneal (curvatura, elevación y paquimetría) del sujeto. En lugar de utilizar el software Pentacam para el análisis de características o la selección para la decisión final, obtenemos los datos brutos (tres archivos CSV que incluyen cinco matrices por cada muestra) mediante una función de exportación por lotes. Este estudio fue aprobado por el Comité de Ética en Investigación (IRB) del 2.º Hospital Afiliado de la Facultad de Medicina de la Universidad de Zhejiang.

2) Descripción de los datos: Para cada muestra, los datos corneales exportados consisten en cinco matrices numéricas, cada una de un tamaño de 141×141 (lo que corresponde a un radio de 7 mm). En este trabajo, tratamos las cinco matrices numéricas como cinco cortes de imagen bidimensionales, denominados CUR-F, CUR-B, ELE-F, ELE-B y PAC, que corresponden a las curvaturas de las superficies anterior y posterior, las elevaciones de las superficies anterior y posterior y la paquimetría de un ojo. La fig. 2 muestra un ejemplo de queratocono con cinco cortes. A continuación, realizamos un análisis estadístico de los cinco cortes en tres grupos (normal, queratocono subclínico y queratocono), respectivamente. Cabe señalar que, debido a la cobertura de las pestañas, los párpados, etc., solo la parte central de cada matriz así obtenida es válida (alrededor de 5 mm) [42], mientras que los datos más allá de los 5 mm pueden presentar algunas pérdidas. Por lo tanto, solo se analizan los datos dentro de los 5,5 mm, siguiendo los procedimientos descritos en [43]. Concretamente, tomando como ejemplo las matrices CUR-F del grupo normal, calculamos los valores de la media y la desviación estándar de los elementos situados en un círculo de radio r . Los valores de r oscilan entre 0,5 y 5,5 mm, en intervalos de 0,5 mm. Es decir, hay 11 valores de r , lo que da lugar a 11 valores de media y desviación estándar. Se llevan a cabo las mismas operaciones para las matrices de CUR-B, ELE-F, ELE-B y PAC en los tres grupos, lo que da lugar a las cinco subfiguras de la fig. 2.

Al examinar la figura 2, se observa en primer lugar que las muestras de queratocono parecen presentar algunas características evidentes en las muestras de tipo CUR-F y CUR-B. En concreto, en la posición central (dentro de los 3 mm), los valores medios y de desviación estándar de las muestras de queratocono son claramente inferiores a los de las muestras de queratocono subclínico y normales. La segunda observación que se desprende de la figura 2 es que las tres curvas de ELE-F están bastante próximas entre sí, y lo mismo ocurre con las de ELE-B. Esto indica que, desde el punto de vista estadístico, las muestras de los tres grupos diferentes son difíciles de distinguir basándose en las matrices de ELE-F y ELE-B. Además, cabe destacar que, en las cinco subfiguras, en todas las posiciones muestreadas (círculos muestreados con diferentes valores de r), los valores medios y de desviación estándar de las muestras de queratocono subclínico son bastante similares a los de las muestras normales. Es decir, la distribución de las muestras de queratocono subclínico no muestra características significativamente diferentes. Esto parece indicar que la detección de muestras de queratocono subclínico entre otras muestras resulta complicada, especialmente entre las muestras normales.

B. KerNet

Cabe imaginar que, para cada muestra, las cinco secciones (CUR-F, CUR-B, ELE-F, ELE-B y PAC) estén relacionadas de algún modo entre sí, ya que se obtienen mediante las mismas operaciones de exploración en el mismo ojo. No obstante, teniendo en cuenta que cada sección contiene información del mismo ojo desde distintas perspectivas, sostenemos que es probable que la correlación entre las cinco secciones no sea tan fuerte como la que existe entre los distintos canales de una imagen RGB. En consecuencia, nuestra red KerNet está diseñada para tener en cuenta de forma moderada dicha correlación entre las cinco secciones, al tiempo que extrae información de cada una de ellas. Esta novedosa estructura consta de cinco ramas, cada una de las cuales toma una sección como entrada. Además, introducimos la idea de la fusión multinivel basada en un mecanismo de fusión multimodal (es decir, tanto fusión de bajo nivel como de alto nivel), con el fin de fusionar las características extraídas de las diferentes secciones. La fig. 1 muestra una visión general de nuestra red KerNet.

1) *Estructura principal*: Nuestra red KerNet consta de cinco ramas que reciben como entrada, respectivamente, cinco secciones de imagen, en lugar de tomarlas simplemente como una entrada global de cinco canales. La tarea de cada rama es procesar una sección de entrada y extraer información de ella. La arquitectura de las ramas consta de una capa convolucional general (seguida de una capa de normalización por lotes y una función de activación ReLU) y cuatro bloques residuales básicos en secuencia, tal y como se ilustra en la fig. 1. Cada bloque residual cuenta con dos bloques básicos de conexión residual, al igual que en ResNet [5]. Dada una entrada x , las características de salida de un bloque básico se denotan como $ReLU(F(x) + x)$ [5]. La función $F(x)$ se implementa mediante dos capas convolucionales, cada una seguida de una capa de normalización por lotes (véase la fig. 3). Tras cada bloque residual, llevamos a cabo la operación de submuestreo mediante max pooling. Optamos por la estructura de bloques residuales en KerNet debido a: (1) su estructura bien diseñada para la extracción de características [5] y (2) sus amplias aplicaciones y su excelente

rendimiento en otras tareas de reconocimiento de imágenes [44].

Concretamente, adaptamos cada bloque residual en función del tamaño de las características de entrada. En este trabajo, todas las matrices (la entrada




Fig. 3. Estructura detallada de un bloque residual.

) se recortan en su región central de tamaño 101×101 , lo que corresponde a unos $5 \text{ mm} \times 5 \text{ mm}$, por dos motivos:

1) los conocimientos médicos previos sobre la detección de enfermedades clínicas (queratocono y queratocono subclínico), y 2) la distribución de los datos del conjunto de datos utilizado en esta investigación. Cabe señalar que numerosos estudios previos (p. ej., [42], [45]) han demostrado que los datos corneales de la región central de $5 \text{ mm} \times 5 \text{ mm}$ son clínicamente significativos para la detección del queratocono y del queratocono subclínico. Además, el análisis estadístico de la sección III-A2 indica que los datos más allá de $5 \text{ mm} \times 5 \text{ mm}$ presentan cierta falta de información. Para que nuestro modelo sea más fiable, solo se utilizan los datos más fiables para el entrenamiento y la evaluación del modelo. De este modo, dada una sección de entrada I_i , los mapas de características de salida del primer bloque residual en cada rama (denominados R_{i1} para la rama i) tienen un tamaño de $64 \times 26 \times 26$. En la figura 1 se ilustran más detalles.

2) Fusión de bajo nivel y fusión de alto nivel: La arquitectura de nuestra fusión multinivel (fusión de bajo nivel y fusión de alto nivel) desempeña un papel importante en nuestra KerNet. Concretamente, llevamos a cabo la fusión de bajo nivel después de los primeros bloques residuales y la fusión de alto nivel antes de la capa de salida, tal y como se destaca en la fig. 1. Realizamos estas operaciones de fusión por dos motivos. Por un lado, por lo general, las características de bajo nivel captadas por una CNN proporcionan más información espacial, mientras que las de alto nivel aportan más información semántica [46]. Sostenemos que tanto las características espaciales como las semánticas extraídas en diferentes ramas (a partir de diferentes cortes de entrada) deben fusionarse para obtener una mejor predicción. Por otro lado, sospechamos que un número excesivo de operaciones de fusión (por ejemplo, fusionar tras cada bloque residual) podría resultar redundante. La eficacia de estas dos consideraciones y de dicha estructura se verifica en la sección IV.

Para la fusión de bajo nivel, establecemos conexiones cruzadas entre las ramas vecinas con el fin de fusionar características, e introducimos un mecanismo de atención para mejorar la fusión mediante un módulo de atención espacial específico. Concretamente, tomamos como ejemplo el mapa de características de la segunda rama para la explicación. Dada la sección de entrada de esta rama, I_2 , de tamaño $1 \times 101 \times 101$, tras la capa convolucional general y el primer bloque residual, el mapa de características tiene un tamaño de $64 \times 26 \times 26$. A continuación, este mapa de características se concatena con los de las dos ramas vecinas (la 1.ª y la 3.ª ramas) en la dimensión de canal, generando un nuevo mapa de características de tamaño 192

$\times 26 \times 26$. Las mismas operaciones de concatenación se realizan en las otras cuatro ramas. Cabe señalar que es diferente




Fig. 4. Estructura detallada de un módulo de atención espacial.

que tanto los mapas de características de la 1.ª como de la 5.ª rama tras la concatenación, tienen un tamaño de $128 \times 26 \times 26$, mientras que los de las otras tres ramas tienen un tamaño de $192 \times 26 \times 26$ (como se muestra en la fig. 1). Con los mapas de características concatenados, se lleva a cabo una selección adicional de características y una mejor fusión mediante la introducción de módulos de atención espacial [47]. Dichos módulos de atención espacial han sido ampliamente estudiados [47], y los utilizamos para guiar a KerNet sobre dónde debe prestar más atención. Introducimos estos módulos de atención debido al hecho clínico de que los oftalmólogos suelen prestar más atención a determinadas regiones, y no toda el área de un corte de imagen tiene la misma importancia para el reconocimiento del queratocono.

Como se muestra en la figura 4, para una entrada x , el módulo de atención espacial lleva a cabo primero un max pooling global y un average pooling global para agregar las características de canal de x . A continuación, los mapas de características generados se concatenan para formar el mapa de atención espacial M_x tras una capa de convolución y una función sigmoide, que puede calcularse como:

$$M_x = \frac{1}{1 + \exp(-W \cdot C(\{G_a(x), G_m(x)\}))} \odot x \quad (1)$$

a m
produce

donde G_a es el «global average pooling», G_m es el «global max pooling» y C es la concatenación por canales.

Para la fusión de alto nivel, concatenamos directamente las características de salida de los cuartos bloques de las cinco ramas (tras la operación de agrupación máxima). Por último, utilizamos una capa totalmente conectada para generar la predicción final, que indica la probabilidad de que la muestra de entrada pertenezca a una de las categorías (queratocono, queratocono subclínico o normal).

En esta estructura específica, tenemos en cuenta tres indicios principales de conocimiento previo. (1) Teniendo en cuenta el acceso a los cinco cortes de cada muestra, esperamos que los cinco cortes estén correlacionados entre sí; sin embargo, la relación podría no ser tan fuerte como la que existe entre los tres canales de una imagen RGB. Por lo tanto, se construyen cinco ramas para extraer respectivamente las características de cada corte, y a continuación se realizan operaciones de fusión de bajo nivel y de alto nivel para tener en cuenta la posible correlación entre los diferentes cortes. (2) Estudios previos indicaron que la




Fig. 5. El flujo de trabajo de nuestro enfoque.

Las cinco secciones se organizan de una forma más significativa desde el punto de vista teórico para reducir la carga que supone una disposición ingenua a la hora de establecer conexiones entre las cinco ramas. (3) Clínicamente, los oftalmólogos suelen prestar más atención a determinadas regiones de una sección, en lugar de prestar la misma atención a toda la sección. Por lo tanto, introducimos los módulos de atención espacial en la operación de fusión de bajo nivel para guiar a nuestra red KerNet a funcionar como

un ser humano que analiza los cortes de la imagen. Los resultados experimentales sugieren que este esquema de extracción y fusión de características

información sobre la elevación posterior es de gran importancia en el diagnóstico clínico del queratocono subclínico [43], [48]. Así pues, la rama central se ha diseñado para el corte de imagen de la elevación posterior (ELE-B), de modo que esta rama pueda obtener más características de otros cortes y proporcionar más características a las demás ramas. De esta manera,

IV. EXPERIMENTOS Y RESULTADOS

Llevamos a cabo numerosos experimentos para demostrar la eficacia y la superioridad de nuestro KerNet frente a otros modelos. Para garantizar una comparación imparcial, realizamos todos los experimentos siguiendo el mismo flujo de trabajo, tal y como se ilustra en la [fig. 5](#). Es decir, preprocesamos el conjunto de datos recopilado, entrenamos el modelo y, finalmente, evaluamos su rendimiento. Esta sección sigue dicho flujo de trabajo. En primer lugar, se presentan las operaciones detalladas del preprocesamiento de datos. A continuación, se describen los detalles de la implementación del entrenamiento del modelo (incluidas las funciones de pérdida) y las métricas de evaluación. Por último, presentamos los resultados experimentales y analizamos el rendimiento. Cabe destacar que, dado que nuestro KerNet tiene como objetivo la detección del queratocono y del queratocono subclínico, medimos el rendimiento del modelo basándonos en su capacidad de detección de ambas enfermedades. Además, utilizamos el mapa de activación de clases (CAM) [49] para mostrar en qué se centra nuestro KerNet, con el fin de vincular la capacidad de extracción de características de KerNet con la práctica clínica.

A. Preprocesamiento de datos

Tal y como se describe en la sección III-A2, recopilamos un conjunto de datos propio que contiene 854 muestras, entre las que se incluyen 335 muestras normales, 172 muestras de queratocono subclínico y 347 muestras de queratocono. Para cada muestra, obtenemos cinco matrices numéricas de tamaño 141×141 cada una (denominadas CUR-F, CUR-B, ELE-F, ELE-B, y PAC, respectivamente). Cada matriz numérica se trata como un corte de imagen bidimensional. Es decir, para cada muestra se dispone de cinco cortes de imagen y una etiqueta de referencia L (que indica a qué categoría pertenece la muestra).

En primer lugar, tal y como se hizo en el trabajo anterior (revisado en la sección III-A2), recortamos todas las matrices en su región central de $5 \text{ mm} \times 5 \text{ mm}$ (aproximadamente 101×101 elementos). A continuación, calculamos los valores medios y las desviaciones estándar para los cinco tipos de cortes (es decir, CUR-F, CUR-B, ELE-F, ELE-B y PAC) de todas las muestras, siguiendo el proceso estándar de estandarización de datos (por ejemplo, como en [50]). A continuación, mostramos un ejemplo del cálculo del valor medio y de la desviación estándar de CUR-F del total de N muestras. Al calcular el valor medio y la desviación estándar de CUR-F de cada muestra (para los 101×101 elementos), obtenemos un total de N valores medios y N valores de desviación estándar, correspondientes a las N muestras, respectivamente. A continuación, calculamos la media de los N valores medios para obtener el valor medio de CUR-F y la media de los N valores de desviación estándar para obtener el valor de la desviación estándar de CUR-F. Se realizan las mismas operaciones para los otros cuatro tipos de cortes, con lo que obtenemos cinco valores medios, [7,9; 6,46; 1068,87; 1105,1622], y cinco valores de desviación estándar, [0,66, 0,76, 654,9672, 80,21], para CUR-F, CUR-B, ELE-F, ELE-B y PAC, respectivamente, para todas las muestras. Asimismo, tomamos CUR-F como ejemplo para explicar el funcionamiento de la normalización de datos basada en los valores medios y de desviación estándar mencionados anteriormente. Utilizamos el primer elemento de la lista de valores medios anterior y el primer elemento de la lista de valores de desviación estándar para llevar a cabo la normalización de datos de los cortes de CUR-F de todas las muestras. Se realizan las mismas operaciones de normalización para los demás tipos de cortes de todas las muestras, respectivamente. Para obtener un rendimiento más consistente, dividimos todas las muestras en un conjunto de entrenamiento y un conjunto de prueba en una proporción de 8:2. A continuación, dividimos las muestras del conjunto de entrenamiento en 5 grupos para llevar a cabo una validación cruzada de 5 pliegues y, finalmente, probamos los modelos en el conjunto de prueba. Para garantizar la imparcialidad de la comparación, realizamos todas las operaciones de preprocesamiento anteriores una sola vez y utilizamos el conjunto de datos así procesado para todos los experimentos.

B. Experimentos

1) **Detalles de la implementación:** Nuestro KerNet tiene como objetivo detectar el queratocono «ker» y el queratocono subclínico a partir de muestras, lo que puede considerarse una tarea de clasificación en tres clases. Toma como entrada una muestra de cinco cortes de imagen (I_i , $i \in \{1, 2, 3, 4, 5\}$), cada uno de tamaño 101×101 , y predice la categoría probable (P) de

TABLA I

LISTA DE HIPERPARÁMETROS DE KERNET Y SU ENTRENAMIENTO

Hyper-parameters	Value
Input Size	101×101
Input Dimensions	5
Batch Size	16
Learning Rate	$1e-3$
Weight Decay Constant	$5e-4$
Max Iterations	50000

Utilizamos una pérdida de log-verosimilitud negativa (NLL), una función de pérdida de entropía cruzada con equilibrio de clases [51], que ha demostrado ofrecer grandes ventajas para tareas de clasificación con un conjunto de entrenamiento desequilibrado [51]. La función de pérdida NLL calcula la diferencia entre el valor predicho P y el valor de referencia L de la siguiente manera:

$$L = \sum_{j=1}^C W_j (-\alpha L \log(P) - (1 - \alpha)(1 - Y) \log(1 - P)) \quad (2)$$

donde W_j representa un coeficiente de ponderación, al que se le asignan diferentes valores según la clase $j \in C$ ($C = 3$ en esta tarea). Establecimos varios hiperparámetros para nuestro modelo

KerNet, tal y como se recoge en la Tabla I. Los dos primeros corresponden a la entrada de datos, y los demás, al entrenamiento del modelo. Partimos de una tasa de aprendizaje inicial de $1e-3$, que reducimos mediante una política de decaimiento polinómico de la tasa de aprendizaje. Utilizamos el optimizador Adam con una disminución de pesos de $5e-4$. Probamos experimentalmente diferentes combinaciones de hiperparámetros para obtener un mejor rendimiento, y los valores de la Tabla I dan como resultado el rendimiento final de este trabajo. Por supuesto, el uso de un marco de optimización de hiperparámetros podría ofrecer mejores resultados, pero resulta algo laborioso. En este estudio, todos los modelos se desarrollaron utilizando Python 3.6.8 con la biblioteca de aprendizaje profundo PyTorch. Todos los experimentos se realizaron en una GPU NVIDIA GeForce GTX 1080Ti. La configuración es idéntica para todos los modelos, salvo por algunos hiperparámetros.

2) **Métricas:** Utilizamos múltiples métricas para medir el rendimiento de clasificación de los modelos. En primer lugar, calculamos varias métricas para medir el rendimiento general, entre las que se incluyen la precisión media (ACC), la recuperación media (Recall), la exactitud media (Precision), el índice F1 (F1) y el valor kappa (κ). Todas estas métricas se calculan en función del rendimiento de clasificación para las tres categorías (normal, queratocono y queratocono subclínico). Dados los verdaderos positivos (TP), los falsos positivos (FP), los verdaderos negativos (TN) y los falsos negativos (FN) de todas las categorías, estas métricas pueden calcularse como:

$$TP + TN$$

de la muestra. Concretamente, los I_i , $i = 1, 2, \dots, 5$, corresponden a CUR-B, CUR-F, ELE-B, ELE-F y PAC. Sin embargo, este

tarea de clasificación debe abordar el problema del desequilibrio en la distribución de los datos para el entrenamiento del modelo, tal y como se describe en la sección III-A2. El número de muestras de queratocono subclínico recopiladas en nuestro conjunto de datos es de solo 172, casi la mitad que el de las muestras de queratocono (347) y las muestras normales (335). Por lo tanto, para entrenar KerNet,

$$ACC = \frac{TP + FP + TN + FN}{TP + FP + TN + FN} \quad (3)$$

$$Recuperación = \frac{TP}{TP + FN} \quad (4)$$

$$Precisión = \frac{TP}{TP + FP} \quad (5)$$

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recuperación}}{\text{Precisión} + \text{Recuperación}} \quad (6)$$

Concretamente, el valor kappa es una medida de concordancia entre la predicción P y la etiqueta de referencia L . Cuanto mayor sea su valor, mayor será la precisión del modelo. Se puede calcular de la siguiente forma:

$$\kappa = (p_o - p_e) / (1 - p_e) \quad (7)$$

donde p_o es la precisión total de clasificación (se puede calcular mediante la ecuación (3)), y p_e puede calcularse como $p_e = \frac{\sum_{i=1}^C a_i \times b_i}{n \times n}$, donde

C es el número de categorías, n es el número total de muestras, a_i es el número de muestras esperadas y b_i es el número de muestras predichas de la clase i .

A continuación, calculamos los valores de precisión y las puntuaciones F1 para las clases de queratocono y queratocono subclínico, respectivamente. Estas dos métricas se utilizan para evaluar el rendimiento global del modelo en las clases objetivo, incluyendo la precisión y el recuerdo. Por comodidad, denotamos estas dos métricas como ACC_k y $F1_k$ para el queratocono, y ACC_s y $F1_s$ para el queratocono subclínico.

Además, presentamos las curvas de características operativas del receptor (ROC) y los valores de AUC para las redes comparadas, con el fin de medir el rendimiento de la clasificación. El AUC se define como el área de la curva ROC, que viene determinada por la tasa de verdaderos positivos (TPR) y la tasa de falsos positivos (FPR), respectivamente. La TPR y la FPR vienen dadas por:

$$TPR = \frac{TP}{TP + FN} \quad (8)$$

$$FPR = \frac{FP}{FP + TN} \quad (9)$$

Por lo tanto, el AUC puede calcularse mediante la ecuación (10).

$$AUC = \int_0^1 TPR(FPR^{-1}(x))dx = P(X_1 > X_0) \quad (10)$$

donde X_1 es la puntuación de una instancia positiva y X_0 es la puntuación de una instancia negativa.

C. Resultados experimentales

En esta sección, presentamos en primer lugar el rendimiento de nuestra red KerNet y analizamos la eficacia de su estructura y componentes específicos. A continuación, demostramos el rendimiento superior de KerNet en comparación con otros métodos, desde el punto de vista de la estructura de la red y el esquema de datos de entrada. Por último, utilizamos los mapas de activación de clases ponderados por gradiente (Grad-CAM) [49] para mostrar en qué se centra nuestra red KerNet, lo que relaciona el rendimiento del modelo con la práctica clínica. Todos los modelos comparados se han implementado de acuerdo con los artículos originales. Todos los parámetros para la prueba final se han seleccionado en función del mejor rendimiento de recuperación en el conjunto de validación.

1) Rendimiento de KerNet: En este apartado, presentamos el rendimiento de KerNet e investigamos varias operaciones

resultado. Es decir, la estructura de las cinco ramas independientes con una operación de fusión de alto nivel se considera nuestro modelo de referencia. En

este caso, con cuatro posibilidades diferentes de colocar las operaciones de fusión de características y dos tipos de opciones de fusión (operación de fusión ingenua y adición de módulos de atención espacial), llevamos a cabo los experimentos con un total de quince estructuras diferentes. La primera fila de la Tabla II ofrece un rendimiento de referencia y la tercera fila muestra el rendimiento de nuestra KerNet. De la segunda a la novena

las filas muestran los resultados de ir añadiendo progresivamente más

y más operaciones de fusión de características. Las filas 10 a 15 muestran los resultados de colocar individualmente las operaciones de fusión de características en diferentes ubicaciones posibles.

Obviamente, la estructura final de nuestra KerNet ofrece un rendimiento ligeramente mejor (es decir, los resultados de la tercera fila), alcanzando un buen equilibrio entre la precisión de predicción y el número de parámetros. Observamos que (desde la segunda hasta la novena fila) no por añadir más operaciones de fusión de características al modelo de referencia se obtiene un mejor rendimiento del modelo. Esto corrobora en cierta medida el análisis teórico presentado en la sección III-B: aunque se espera que se fusionen tanto las características de bajo nivel como las de alto nivel, un número excesivo de operaciones de fusión dará lugar a redundancia (lo que conlleva costes computacionales adicionales pero una mejora mínima del rendimiento).

Además, se puede observar que, entre todas las ubicaciones posibles para aplicar las operaciones de fusión de características, bajo la premisa de una fusión «ingenua», añadir un módulo de atención espacial adicional...

La aplicación de reglas en las ubicaciones de bajo nivel mejora notablemente el rendimiento (por ejemplo, añadiendo los módulos de atención espacial después del primer bloque residual, tal y como se muestra en la segunda y tercera filas), pero posibles que consisten simplemente en fusionar características y añadir módulos de atención adicionales bajo la premisa de una fusión ingenua. Aquí, mantenemos sin cambios la operación de fusión final (la operación de concatenación final y la capa totalmente conectada) para todas las estructuras probadas, ya que se espera que la red genere una predicción

no mismo no se cumple para las ubicaciones de alto nivel. Como se muestra en la [Tabla II](#), en las ubicaciones de alto nivel, los módulos de atención espacial adicionales pueden aportar poca mejora (p. ej., como se muestra en las filas octava y novena, la penúltima y la última), o incluso conducir a un peor rendimiento (p. ej., como se muestra en las filas cuarta y quinta, en las filas sexta y séptima, en las filas décima y undécima, y en las filas duodécima y decimotercera). Esto se debe posiblemente a que nuestros módulos de atención espacial permiten a la red prestar más atención a la información espacial. Cabe señalar que es bien sabido que las características de alto nivel tienden a expresar más información semántica, pero carecen de características espaciales distintivas [52].

2) Comparación con otros métodos: A continuación, comparamos el rendimiento de KerNet con el de otros métodos conocidos, desde dos perspectivas: (1) la estructura del modelo y (2) el esquema de datos de entrada. En primer lugar, comparamos el rendimiento de diferentes estructuras de modelo, incluidos varios modelos representativos de clasificación de imágenes, como LeNet [53], AlexNet, VGGNet, ResNet18, ResNet50, DenseNet y SE-ResNet. Estos modelos funcionan de forma integral, recibiendo los cinco cortes como entrada y realizando la predicción directamente. Cabe destacar que nuestro KerNet toma como entrada cinco cortes de imagen separados (un corte por rama), mientras que los demás modelos reciben los cinco cortes en su conjunto (una entrada de 5 canales). La [Tabla III](#) muestra los resultados detallados. Para una comparación más completa, presentamos las curvas de características operativas del receptor (ROC) de estas redes, tal y como se muestra en la [Fig. 6](#). Evidentemente, tanto para la detección del queratocono como del queratocono subclínico, KerNet alcanza un rendimiento de vanguardia en casi todas las

TABLA II

EL RENDIMIENTO DE NUESTRA RED KERNet Y SUS VARIANTES UTILIZANDO DIFERENTES OPCIONES DE FUSIÓN DE CARACTERÍSTICAS (YA SEA UNA OPERACIÓN DE FUSIÓN DE CARACTERÍSTICAS «NAIVE» O MÓDULOS DE ATENCIÓN ESPACIAL ADICIONALES) EN DIFERENTES UBICACIONES DE LA RED. POR COMODIDAD, UTILIZAMOS « aR_i » PARA INDICAR LA ADICIÓN DE OPERACIONES DE FUSIÓN DE CARACTERÍSTICAS TRAS EL i -ésimo BLOQUE RESIDUAL DE CADA RAMA. EL USO DE LA OPERACIÓN DE FUSIÓN DE CARACTERÍSTICAS «NAIVE» Y LA ADICIÓN DE MÓDULOS DE ATENCIÓN ESPACIAL ADICIONALES SE ABREVIAN COMO «N» Y «A», RESPECTIVAMENTE. EL QUERATOCONO Y EL QUERATOCONO SUBCLÍNICO SE ABREVIAN COMO «KC» Y «SKC». LA TERCERA FILA MUESTRA EL RENDIMIENTO DE KERNet

Locations				Options		Metrics (%)								
aR_1	aR_2	aR_3	aR_4	N	A	SKC		KC		Total				
						ACC_s	$F1_s$	ACC_k	$F1_k$	ACC	$Recall$	$Precision$	$F1$	κ
×	×	×	×	×	×	94.15	84.38	97.08	96.45	92.98	90.69	92.40	91.42	88.94
✓	×	×	×	✓	×	94.74	87.67	97.08	96.40	93.57	93.63	91.99	92.64	90.03
✓	×	×	×	✓	✓	95.91	91.18	98.25	98.57	94.74	93.71	94.10	93.89	91.78
✓	✓	×	×	✓	×	94.15	86.11	98.25	97.87	92.98	92.60	91.31	91.82	89.10
✓	✓	×	×	✓	✓	92.98	83.78	97.66	97.06	92.40	92.17	90.45	91.09	88.24
✓	✓	✓	×	✓	×	95.32	88.24	97.66	97.10	94.15	93.16	93.17	93.15	90.86
✓	✓	✓	×	✓	✓	94.74	86.57	97.66	97.18	93.57	92.13	92.55	92.33	89.92
✓	✓	✓	✓	✓	×	92.40	83.12	97.08	96.35	91.23	91.66	89.34	90.03	86.50
✓	✓	✓	✓	✓	✓	93.57	84.93	97.66	97.10	92.98	92.65	91.11	91.72	89.12
×	✓	×	×	✓	×	92.39	90.59	97.66	97.05	91.81	89.73	90.23	89.91	87.18
×	✓	×	×	✓	✓	91.22	81.01	98.24	97.81	90.64	91.13	88.67	89.23	85.65
×	×	✓	×	✓	×	91.81	80.55	98.24	97.81	91.22	90.18	89.07	89.53	86.38
×	×	✓	×	✓	✓	91.39	80.12	97.07	96.40	90.81	89.71	89.07	89.88	87.17
×	×	×	✓	✓	×	91.22	80.45	97.66	97.05	90.64	89.71	88.42	88.91	85.50
×	×	×	✓	✓	✓	91.56	82.05	98.24	97.84	91.98	90.65	90.31	90.47	88.04

TABLA III

COMPARACIÓN ENTRE NUESTRO MODELO KERNet Y VARIOS MODELOS DE USO HABITUAL. KERNet RECIBE CINCO CORTES INDIVIDUALES DE UNA MUESTRA (UNO POR RAMA), MIENTRAS QUE LOS DEMÁS MODELOS RECIBEN ESTOS CORTES EN SU CONJUNTO (UNA ENTRADA DE 5 CANALES). EL QUERATOCONO Y EL QUERATOCONO SUBCLÍNICO SE DENOMINAN «KC» Y «SKC», RESPECTIVAMENTE

Model	Metrics (%)								
	SKC		KC		Total				
	ACC_s	$F1_s$	ACC_k	$F1_k$	ACC	$Recall$	$Precision$	$F1$	κ
KerNet	95.91	91.18	98.25	98.57	94.74	93.71	94.10	93.89	91.78
LeNet	84.21	76.47	95.91	95.71	83.63	81.02	82.27	80.94	74.87
AlexNet	93.57	88.24	97.66	97.14	92.40	90.66	91.64	91.08	88.17
VGGNet	86.55	61.76	95.91	97.14	85.96	82.49	81.82	82.10	77.92
ResNet18	90.06	82.35	97.66	95.71	87.45	86.98	88.21	87.45	83.69
ResNet50	92.40	85.29	96.49	97.14	91.23	89.27	90.17	89.64	86.35
DenseNet	86.55	70.59	97.66	98.57	85.38	82.15	82.75	82.30	77.24
SE-ResNet	80.12	67.65	95.32	98.57	79.53	76.86	77.30	75.96	68.62
FFN [25]	85.96	68.42	97.08	96.40	84.80	83.26	81.89	82.24	76.55

métricas. Además, KerNet muestra una notable superioridad en la detección del queratocono subclínico, aunque todos los demás modelos parecen ofrecer un buen rendimiento en la detección del queratocono. En la detección del queratocono subclínico, nuestro modelo KerNet supera a todos los demás modelos en un 3,4 %-15,8 % en cuanto a la tasa de acierto (ACC) y en un 3 %-13 % en cuanto a la **área bajo la curva (AUC)**, lo que supone una mejora significativa. Por lo tanto, KerNet ofrece un método más eficaz para distinguir el queratocono subclínico que otros métodos, lo que puede paliar el difícil problema que supone la gran dificultad para detectar las muestras de queratocono subclínico [3].

A continuación, presentamos los resultados de la FFN propuesta en [25], que es uno de los pocos enfoques existentes basados en datos brutos del sistema Pentacam HR (véase la última fila de la **Tabla III**). La FFN, construida siguiendo el artículo original [25], lleva a cabo la selección de parámetros en la primera etapa y realiza la predicción final en la segunda etapa. Aunque la FFN obtiene un rendimiento comparable al de nuestra KerNet en la detección del queratocono, nuestra KerNet muestra una superioridad notable en la detección del queratocono subclínico. Además, nuestra KerNet funciona de forma integral,




Fig. 6. Las curvas ROC de nuestra red KerNet y de varios modelos de uso habitual. La parte izquierda muestra el rendimiento de los modelos en la detección del queratocono subclínico y la parte derecha muestra el rendimiento en la detección del queratocono.

TABLA IV

COMPARACIÓN DE DIFERENTES ESQUEMAS DE DATOS DE ENTRADA, UTILIZANDO RESNET18 COMO EJEMPLO. EL QUERATOCONO Y EL QUERATOCONO SUBCLÍNICO SE DENOTAN COMO «KC» Y «SKC», RESPECTIVAMENTE

Input Data	Metrics (%)								
	SKC		KC		Total				
	ACC_s	$F1_s$	ACC_k	$F1_k$	ACC	$Recall$	$Precision$	$F1$	κ
ELE-B	88.30	65.52	96.49	95.71	87.72	82.37	86.00	83.37	80.45
CUR-B	87.72	66.67	95.91	95.10	86.55	82.32	83.69	82.85	78.77
CUR-F	84.21	65.82	96.49	95.59	84.21	82.81	81.53	81.63	75.79
PAC	83.04	60.27	93.57	92.62	81.87	78.80	78.73	78.19	71.85
ELE-F	76.61	58.33	94.15	92.96	75.44	76.29	77.14	72.87	63.38
Five Slices (Whole)	90.06	82.35	97.66	95.71	87.45	86.98	88.21	87.45	83.69
Five Slices (Separate)	94.15	84.38	97.08	96.45	92.98	90.69	92.40	91.42	88.94

lo que significa que no se necesitan intervenciones humanas para la selección de características.

Comparamos los efectos de diferentes esquemas de datos de entrada. Para llevar a cabo los experimentos, utilizamos simplemente una red ResNet18, que puede mantener una estructura similar a la de KerNet. Los experimentos se realizan alimentando la red ResNet18 con diferentes números de cortes de imagen (uno o cinco). La [tabla IV](#) muestra los resultados. Las primeras cinco filas recogen los resultados obtenidos al adaptar ResNet18 para una entrada de un solo canal y proporcionarle un corte cada vez. Las dos últimas filas muestran los resultados al adaptar ResNet18 para recibir los cinco cortes simultáneamente. La penúltima fila muestra los resultados de una red que recibe una entrada completa de cinco canales (*Cinco cortes (Completa)*) para la predicción. La última fila corresponde a los resultados de una red con la misma estructura que la de la primera fila de la [Tabla II](#), que recibe las cinco secciones (*Cinco secciones (separadas)*) mediante cinco ramas independientes y fusiona las características de alto nivel de cada sección.

En primer lugar, observamos que, con la misma estructura principal, el modelo obtiene un mejor rendimiento cuando recibe toda la información de las cinco secciones simultáneamente, en comparación con recibir una de ellas cada vez. Esta observación puede deducirse de los experimentos tanto para la detección del queratocono como para la detección del queratocono subclínico. En segundo lugar, los resultados de recibir los cinco cortes por separado (los resultados de la última fila de la [Tabla IV](#)) son mejores que los de recibirlos en su conjunto. Estos resultados podrían respaldar

nuestra opinión de que la correlación entre los cinco cortes no es tan fuerte como la que existe entre los diferentes canales de una imagen RGB (en la sección III-B). Por lo tanto, el simple hecho de tratar los cinco cortes como un todo conduce a una fusión excesiva de características y, posiblemente, a un rendimiento no muy bueno. Por supuesto, nuestra estructura específica de KerNet, que tiene en cuenta de forma moderada la posible correlación de los cinco cortes, muestra un mejor rendimiento. La tercera observación de la Tabla IV es que, al recibir un corte como entrada, el modelo que recibe un corte ELE-B alcanza un rendimiento ligeramente mejor para la detección del queratocono subclínico en comparación con los demás. Esto corrobora aún más las investigaciones previas que indican que los perfiles de elevación posterior son de gran importancia en el diagnóstico del queratocono subclínico [43], [48], tal y como se menciona en la Sección III-B.

Además de las notables mejoras de rendimiento de nuestra red KerNet, en comparación con las redes de última generación (especialmente para la detección del queratocono subclínico), es posible que suponga un mayor consumo de memoria y tiempo. Nuestra red KerNet contiene cerca de 61,03 millones de parámetros y realiza la predicción de una muestra en aproximadamente 0,02 segundos. En cuanto a AlexNet, que alcanza el segundo mejor rendimiento en la detección del queratocono subclínico, contiene una cantidad similar de parámetros (61,10 M), mientras que realiza la predicción de una muestra en tan solo 0,001 segundos. En el caso de ResNet18, a pesar de su bajo rendimiento, es más ligera (con 11,708 M




Fig. 7. Visualización de los mapas de atención generados por Grad-CAM [49]. La parte superior muestra el mapa de atención global para todas las muestras del *Grupo 1* (el mapa superior izquierdo) y los mapas de atención de 12 muestras seleccionadas al azar del *Grupo 1* (es decir, muestras correctamente predichas como queratocono). Del mismo modo, la parte inferior corresponde a las muestras del *Grupo 2* (es decir, muestras correctamente predichas como queratocono subclínico).

parámetros) y puede realizar predicciones más rápidas (en 0,006 s). Ante las desventajas que suponen los elevados costes de memoria y tiempo, en nuestro estudio futuro intentaremos lograr un mejor equilibrio entre los costes y el rendimiento del modelo.

3) *Visualización Grad-CAM*: Siguiendo el método Gradient-weighted Class Activation Mappings (Grad-CAM) [49], llevamos a cabo un experimento para visualizar en qué zonas se fija nuestro KerNet a la hora de distinguir los casos de queratocono y de queratocono subclínico de los casos normales. Para la clase objetivo, Grad-CAM utiliza el gradiente de la última capa convolucional para generar un mapa de atención, que resalta qué áreas de la imagen son importantes y permiten discriminar la clase en la detección de la clase objetivo. En cuanto a las tareas específicas del análisis de imágenes médicas, algunos investigadores también han utilizado Grad-CAM para la detección de lesiones, ya que las regiones rojas correspondientes a puntuaciones elevadas en la detección de muestras patológicas podrían indicar las áreas de lesión [54], [55]. En este trabajo, adaptamos el funcionamiento de Grad-CAM de acuerdo con la estructura específica de nuestra red KerNet, tal y como se ilustra en la fig. 8. En primer lugar, los mapas de características de salida de las últimas cinco capas convolucionales de KerNet (cinco mapas de características de $512 \times 7 \times 7$) se concatenan en su conjunto, lo que se considera como los mapas de características de salida de la «capa convolucional final» de KerNet, tal y como se describe en [49]. A continuación, Grad-CAM utiliza la información de gradiente que fluye hacia la **capa convolucional final para generar un mapa de atención que resalte las regiones importantes de la imagen para la predicción**. El cálculo más detallado de este proceso se explicó en [49].

Utilizamos Grad-CAM para generar mapas de atención para todas las muestras que se han predicho correctamente como afectadas por enfermedades (es decir, las muestras de queratocono y de queratocono subclínico), ya que nuestro KerNet tiene como objetivo detectar aquellas muestras que muestran posibles regiones de lesión. Las muestras predichas

correctamente como queratocono se denominan *Grupo 1* y las predichas correctamente como queratocono subclínico se denominan *Grupo 2*. Para las muestras de

...

...

...

...




fig. 8. Ilustración de la operación específica de Grad-CAM utilizada en este estudio, siguiendo el trabajo de [49].

Grupo 1, calculamos la media de todos los mapas de atención (a nivel de píxel) para obtener un mapa de atención global, que es el mapa superior izquierdo de la parte superior de la fig. 7. Dicho mapa de atención global indica en qué lugares centra su atención KerNet al distinguir las muestras de queratocono de las demás (queratocono subclínico y muestras normales). Las regiones rojas corresponden a puntuaciones altas en la detección del queratocono, lo que indica una fuerte atención por parte de KerNet. Las regiones azules representan puntuaciones bajas y poca atención. Además, se seleccionan aleatoriamente 12 muestras del Grupo 1 y sus mapas de atención se muestran en la parte superior de la figura 7 (a la derecha del mapa de atención global). Las mismas operaciones para las muestras del Grupo 2 y los mapas de atención se muestran en la parte inferior de la figura 7. Cabe destacar que las regiones rojas (las áreas de enfoque de nuestra red KerNet) suelen aparecer en las partes inferiores izquierdas de los

mapas de atención, lo que se corresponde con la parte temporal inferior de los ojos (tal y como se explica en la sección III-A2). Al mismo tiempo, las regiones rojas de las muestras de queratocono son, en general, más grandes que las de las muestras de queratocono subclínico. Estas observaciones coinciden con estudios previos que indican que, tanto en las muestras de queratocono como en las de queratocono subclínico: 1) la mayoría de los conos se localizaban en el cuadrante temporal inferior [56], [57], y 2) las muestras de queratocono suelen presentar lesiones más graves [58].

Los resultados anteriores han sido verificados por dos expertos independientes. Es decir, nuestro modelo KerNet identifica adecuadamente las regiones discriminativas de las muestras de queratocono y de queratocono subclínico, lo cual concuerda con las regiones de atención humana de dichas muestras.

V. DISCUSIÓN Y CONCLUSIONES

En este artículo, hemos presentado un novedoso enfoque de aprendizaje profundo de extremo a extremo, denominado KerNet, para la detección del queratocono y del queratocono subclínico, utilizando los datos brutos del sistema Pentacam HR. Los datos brutos exportados del sistema Pentacam HR tienen un formato específico, que consta de cinco cortes por cada muestra (CUR-F, CUR-B, ELE-F, ELE-B y PAC). En consecuencia, hemos incorporado cinco ramas en nuestro KerNet para recibir los cinco cortes por separado, y hemos introducido el concepto de fusión multinivel (es decir, fusión de bajo nivel y fusión de alto nivel) para tener en cuenta de forma moderada la posible correlación entre los cinco cortes. Concretamente, hemos introducido el mecanismo de atención, utilizando módulos espaciales, para mejorar la fusión de bajo nivel. Para la fusión de alto nivel, solo se lleva a cabo una simple concatenación por canales. Los experimentos de evaluación comparativa realizados con nuestro conjunto de datos interno demostraron que nuestra red KerNet propuesta puede alcanzar resultados mucho mejores que los métodos de vanguardia, especialmente en la detección del queratocono subclínico. Además, los mapas de atención generados por Grad-CAM mostraron que nuestra red KerNet presta mayor atención a la parte temporal inferior de las muestras de queratocono y de queratocono subclínico (de acuerdo con los expertos clínicos).

Según nuestro conocimiento, somos los primeros en proponer un enfoque de aprendizaje profundo de extremo a extremo que utilice datos sin procesar obtenidos mediante el sistema Pentacam HR para la detección del queratocono y del queratocono subclínico. Aunque nuestra red KerNet alcanza un alto rendimiento en la detección del queratocono y del queratocono subclínico, es posible que suponga un mayor consumo de memoria y tiempo en comparación con algunas redes existentes (tal y como se analiza en la sección IV-C). Además, todavía no puede determinar los subtipos ni la gravedad del queratocono, aspectos que abordaremos en nuestras futuras investigaciones.

REFERENCIAS

- [1] H. Hashemi *et al.*, «The prevalence and risk factors for keratoconus: A systematic review and meta-analysis», *Cornea*, vol. 39, n.º 2, pp. 263-270, 2020.
- [2] N. Hallett *et al.*, «Clasificación no supervisada y semisupervisada basada en el aprendizaje profundo para el queratocono», 2020, *arXiv:2001.11653*.
- [3] D. Smadja *et al.*, «Detección del queratocono subclínico mediante una clasificación automatizada con árboles de decisión», *Amer. J. Ophthalmol.*, vol. 156, n.º 2, pp. 237-246, 2013.
- [4] F. Toutounchian, J. Shanbehzadeh, M. Khanlari y A. Stage, «Detección del queratocono y del queratocono sospechoso mediante visión artificial», en *Actas de la Conferencia Internacional Multidisciplinaria de Ingenieros e Informáticos*, 2012, pp. 1-3.
- [5] K. He, X. Zhang, S. Ren y J. Sun, «Aprendizaje residual profundo para el reconocimiento de imágenes», en *Actas de la Conferencia IEEE sobre Visión por Ordenador y Reconocimiento de Patrones*, 2016, pp. 770-778.

- [6] J. Du, W. Li, K. Lu y B. Xiao, «Una visión general de la fusión multimodal de imágenes médicas», *Neurocomputing*, vol. 215, pp. 3-20, 2016.
- [7] J. S. Velázquez-Blázquez *et al.*, «Detección del queratocono subclínico mediante parámetros biométricos», en *Actas de la Conferencia Internacional sobre Bioinformática e Ingeniería Biomédica*, 2019, pp. 490-501.
- [8] I. A. N. Omar, «Cribado del queratocono en niños miopes», *Clin. Ophthalmol.* (Auckland, Nueva Zelanda), vol. 13, 2019, art. n.º 1909.
- [9] F. M. Elhennawi, Y. A. Alzankalony, M. K. Abdellatif y A. M. Tawfik Ibrahim, «Papel de la tomografía de coherencia óptica del segmento anterior en el diagnóstico del queratocono subclínico en comparación con el Pentacam», *Egyptian J. Hosp. Med.*, vol. 72, n.º 1, pp. 3712-3715, 2018.
- [10] H. Hashemi *et al.*, «Precisión del Pentacam a la hora de distinguir el queratocono de las córneas normales: un estudio de evaluación diagnóstica», **Eye Contact Lens**, vol. 45, n.º 1, pp. 46-50, 2019.
- [11] S. Yousefi *et al.*, «Identificación de la gravedad del queratocono mediante aprendizaje automático no supervisado», *PLoS One*, vol. 13, n.º 11, 2018, art. n.º e0205998.
- [12] M. Malfeito, U. Regueiro, M. Pérez-Mato, F. Campos, T. Sobrino e I. Lema, «Biomarcadores de la inmunidad innata para la detección precoz del queratocono», *Ocular Immunol. Inflammation*, vol. 27, n.º 6, pp. 942-948, 2019.
- [13] I. Kovács *et al.*, «Precisión de los clasificadores de aprendizaje automático que utilizan datos bilaterales de una cámara Scheimpflug para identificar ojos con signos preclínicos de queratocono», *J. Cataract Refractive Surg.*, vol. 42, n.º 2, pp. 275-283, 2016.
- [14] A. Lavric y P. Valentin, «Keratodetect: algoritmo de detección del queratocono mediante redes neuronales convolucionales», *Comput. Intell. Neurosci.*, vol. 2019, 2019, pp. 1-9.
- [15] S. Huseynli, J. Salgado-Borges y J. L. Alio, «Evaluación comparativa de los parámetros de la tomografía de Scheimpflug entre córneas delgadas sin queratocono, con queratocono subclínico y con queratocono leve», *Eur. J. Ophthalmol.*, vol. 28, n.º 5, pp. 521-534, 2018.
- [16] H. Hashemi *et al.*, «Índices de queratocono y sus determinantes en ojos sanos de una población rural», *J. Curr. Ophthalmol.*, 2019.
- [17] M. Koc *et al.*, «Evaluación topométrica y tomográfica del queratocono subclínico», *Ophthalmic Epidemiol.*, vol. 17, n.º 4, pp. 1-9, 2020.
- [18] E. Atalay, O. Özalp, M. A. Erol, M. Bilgin y N. Yildirim, «Un modelo combinado biomecánico y tomográfico para identificar casos de queratocono subclínico», *Cornea*, vol. 39, n.º 4, pp. 461-467, 2020.
- [19] H. Zou, J. Xu, L. Zhang, S. Ji y Y. Wang, «Ayuda al diagnóstico del queratocono subclínico mediante inteligencia artificial», *Chin. J. Ophthalmol.*, vol. 55, n.º 12, pp. 911-915, 2019.
- [20] B. T. Lopes *et al.*, «Evaluación tomográfica mejorada para detectar la ectasia corneal basada en la inteligencia artificial», *Amer. J. Ophthalmol.*, vol. 195, pp. 223-232, 2018.
- [21] I. R. Hidalgo *et al.*, «Evaluación de un clasificador de aprendizaje automático para la detección del queratocono basado en la tomografía de Scheimpflug», *Cornea*, vol. 35, n.º 6, pp. 827-832, 2016.
- [22] H. Hashemi, A. Beiranvand, A. Yekta, A. Maleki, N. Yazdani y M. Khabazkhoob, «Índices de Pentacam para el diagnóstico del queratocono subclínico y confirmado», *J. Curr. Ophthalmol.*, vol. 28, n.º 1, pp. 21-26, 2016.
- [23] D. T. Hogarty, D. A. Mackey y A. W. Hewitt, «Estado actual y perspectivas futuras de la inteligencia artificial en oftalmología: una revisión», *Clin. Exp. Ophthalmol.*, vol. 47, n.º 1, pp. 128-139, 2019.
- [24] Y. Xie *et al.*, «Selección de candidatos para la cirugía refractiva mediante aprendizaje profundo basado en tomografía corneal», *JAMA Ophthalmol.*, vol. 138, n.º 5, pp. 519-526, 2020.
- [25] I. Issarti, A. Consejo, M. Jiménez-García, S. Hershko, C. Koppen y J. J. Rozema, «Diagnóstico asistido por ordenador para la detección de casos sospechosos de queratocono», *Comput. Biol. Med.*, vol. 109, pp. 33-42, 2019.
- [26] A. Krizhevsky, I. Sutskever y G. E. Hinton, «Clasificación de ImageNet con redes neuronales convolucionales profundas», en *Actas de Adv. Neural Inf. Process. Syst.*, 2012, pp. 1097-1105.
- [27] K. Simonyan y A. Zisserman, «Redes convolucionales muy profundas para el reconocimiento de imágenes a gran escala», 2014, *arXiv:1409.1556*.
- [28] C. Szegedy *et al.*, «Going deeper with convolutions», en *Actas de la Conferencia IEEE sobre Visión por Ordenador y Reconocimiento de Patrones*, 2015, pp. 1-9.
- [29] G. Huang, Z. Liu, L. Van Der Maaten y K. Q. Weinberger, «Redes convolucionales densamente conectadas», en *Actas de la Conferencia IEEE sobre Visión por Computador y Reconocimiento de Patrones*, 2017, pp. 4700-4708.
- [30] A. Kumar, J. Kim, D. Lyndon, M. Fulham y D. Feng, «Un conjunto de redes neuronales convolucionales ajustadas con precisión para la clasificación de imágenes médicas», *IEEE J. Biomed. Health Informat.*, vol. 21, n.º 1, pp. 31-40, enero de 2017.

- [31] I. P. Okuwobi, Z. Ji, W. Fan, S. Yuan, L. Bekalo y Q. Chen, «Cuantificación automatizada de focos hiperreflectantes en SD-OCT con retinopatía diabética», *IEEE J. Biomed. Health Informat.*, vol. 24, n.º 4, pp. 1125-1136, abril de 2020.
- [32] P. Burlina, D. E. Freund, N. Joshi, Y. Wolfson y N. M. Bressler, «Detección de la degeneración macular relacionada con la edad mediante aprendizaje profundo», en *Actas del 13.º Simposio Internacional IEEE sobre Imagen Biomédica*, 2016, pp. 184-188.
- [33] X. Xu, L. Zhang, J. Li, Y. Guan y L. Zhang, «Un modelo híbrido de CNN de representación global-local para la clasificación automática de cataratas», *IEEE J. Biomed. Health Informat.*, vol. 24, n.º 2, pp. 556-567, febrero de 2020.
- [34] G. W. Armstrong y A. C. Lorch, «A(eye): Una revisión de las aplicaciones actuales de la inteligencia artificial y el aprendizaje automático en oftalmología», *Int. Ophthalmol. Clin.*, vol. 60, n.º 1, pp. 57-71, 2020.
- [35] D. S. J. Ting *et al.*, «Inteligencia artificial para las enfermedades del segmento anterior: aplicaciones emergentes en oftalmología», *Brit. J. Ophthalmol.*, vol. 105, n.º 2, pp. 158-168, 2021.
- [36] A. Lavric, V. Popa, C. David y C. C. Paval, «Algoritmo de detección del queratocono mediante redes neuronales convolucionales: retos», en *Actas de la 11.ª Conferencia Internacional sobre Electrónica, Informática e Inteligencia Artificial*, 2019, pp. 1-4.
- [37] K. Kamiya *et al.*, «Detección del queratocono mediante aprendizaje profundo de mapas codificados por colores con tomografía de coherencia óptica del segmento anterior: un estudio de precisión diagnóstica», *BMJ Open*, vol. 9, n.º 9, 2019, art. n.º e031313.
- [38] V. A. Dos Santos *et al.*, «CorneaNet: segmentación rápida de exploraciones OCT de la córnea de ojos sanos y con queratocono mediante aprendizaje profundo», *Biomed. Opt. Exp.*, vol. 10, n.º 2, pp. 622-641, 2019.
- [39] R. H. Silverman, R. Urs, A. Roy-Choudhury, T. J. Archer, M. Gobbe y D. Z. Reinstein, «La remodelación epitelial como base para la identificación automática del queratocono», *Invest. Ophthalmol. Vis. Sci.*, vol. 55, n.º 3, pp. 1580-1587, 2014.
- [40] P. A. Accardo y S. Pensiero, «Sistema basado en redes neuronales para la detección precoz del queratocono a partir de la topografía corneal», *J. Biomed. Informat.*, vol. 35, n.º 3, pp. 151-159, 2002.
- [41] P. Zéboulon, G. Debellemanière, M. Bouvet y D. Gatinel, «Clasificación de datos brutos de topografía corneal mediante una red neuronal convolucional», *Amer. J. Ophthalmol.*, vol. 219, pp. 33-39, 2020.
- [42] U. de Sanctis, C. Loiacono, L. Richiardi, D. Turco, B. Mutani y F. M. Grignolo, «Sensibilidad y especificidad de la elevación corneal posterior medida con Pentacam para diferenciar entre queratocono y queratocono subclínico», *Ophthalmology*, vol. 115, n.º 9, pp. 1534-1539, 2008.
- [43] Z. Xu *et al.*, «Valor de los perfiles de grosor vertical del epitelio corneal y de la capa de Bowman generados por UHR-OCT para el diagnóstico del queratocono subclínico», *Sci. Rep.*, vol. 6, n.º 1, pp. 1-11, 2016.
- [44] R. Feng *et al.*, «SSN: una red en forma de escalera para la segmentación en tiempo real de pólipos en imágenes de colonoscopia», en *Actas del 17.º Simposio Internacional IEEE sobre Imagen Biomédica*, 2020, pp. 225-229.
- [45] J. Bühren, D. Kook, G. Yoon y T. Kohnen, «Detección del queratocono subclínico mediante el uso de aberraciones de las superficies anterior y posterior de la córnea y perfiles espaciales de espesor», *Invest. Ophthalmol. Vis. Sci.*, vol. 51, n.º 7, pp. 3424-3432, 2010.
- [46] Z. Zhang, X. Zhang, C. Peng, X. Xue y J. Sun, «ExFuse: mejora de la fusión de características para la segmentación semántica», en *Actas de la Conferencia Europea sobre Visión por Computador*, 2018, pp. 269-284.
- [47] S. Woo, J. Park, J. Y. Lee e I. S. Kweon, «CBAM: Convolutional Block Attention Module», en *Actas de la Conferencia Europea sobre Visión por Computador*, 2018, pp. 3-19.
- [48] M. A. Shousha *et al.*, «El uso del mapa topográfico del grosor vertical de la capa de Bowman en el diagnóstico del queratocono», *Ophthalmology*, vol. 121, n.º 5, pp. 988-993, 2014.
- [49] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh y D. Batra, «Grad-CAM: explicaciones visuales a partir de redes profundas mediante la localización basada en gradientes», en *Actas de la Conferencia Internacional del IEEE sobre Visión por Ordenador*, 2017, pp. 618-626.
- [50] O. Tasar, Y. Tarabalka, A. Giros, P. Alliez y S. Clerc, «Standard-GAN: Adaptación de dominios de múltiples fuentes para la segmentación semántica de imágenes satelitales de muy alta resolución mediante la estandarización de datos», en *Actas de los Talleres de la Conferencia IEEE/CVF sobre Visión por Computador y Reconocimiento de Patrones*, 2020, pp. 192-193.
- [51] J. T. Barron, «Una función de pérdida robusta, general y adaptativa», en *Actas de la Conferencia IEEE sobre Visión por Computador y Reconocimiento de Patrones*, 2019, pp. 4331-4339.
- [52] L.-J. Li, H. Su, L. Fei-Fei y E. P. Xing, «Object Bank: una representación de imágenes de alto nivel para la clasificación de escenas y la dispersión de características semánticas», en *Actas de la Conferencia sobre Sistemas Avanzados de Procesamiento de Información Neural*, 2010, pp. 1378-1386.
- [53] Y. Lecun, L. Bottou, Y. Bengio y P. Haffner, «Aprendizaje basado en gradientes aplicado al reconocimiento de documentos», *Proc. IEEE*, vol. 86, n.º 11, pp. 2278-2324, noviembre de 1998.
- [54] H. Panwar, P. Gupta, M. K. Siddiqui, R. Morales-Menéndez, P. Bhardwaj y V. Singh, «Un enfoque de visualización en color basado en el aprendizaje profundo y Grad-CAM para la detección rápida de casos de COVID-19 mediante radiografías de tórax e imágenes de tomografía computarizada», *Chaos, Solitons Fractals*, vol. 140, 2020, art. n.º 110190.
- [55] H. Jiang *et al.*, «Un modelo de aprendizaje profundo multitiqueta con Grad-CAM interpretable para la clasificación de la retinopatía diabética», en *Actas de la 42.ª Conferencia Anual Internacional de la Sociedad de Ingeniería Médica y Biológica del IEEE*, 2020, pp. 1560-1563.
- [56] Z. Zhang *et al.*, «Asfericidad corneal y sus factores relacionados en 1052 sujetos chinos», *Optometry Vis. Sci.*, vol. 88, n.º 10, pp. 1232-1239, 2011.
- [57] G. U. Auffarth, L. Wang y H. E. Völcker, «Evaluación del queratocono mediante el sistema de topografía Orbscan», *J. Cataract Refractive Surg.*, vol. 26, n.º 2, pp. 222-228, 2000.
- [58] J. C. Reddy, C. J. Rapuano, J. R. Cater, K. Suri, P. K. Nagra y K. M. Hammersmith, «Evaluación comparativa de los parámetros de imagen dual de Scheimpflug en el queratocono, el queratocono en fase inicial y los ojos normales», *J. Cataract Refractive Surg.*, vol. 40, n.º 4, pp. 582-592, 2014.